

Optimisation des Hyperparamètres


Grid Search, Random Search & Optimisation Bayésienne

Plan du Cours

- 1 Contexte
- 2 Grid Search
- 3 Random Search
- 4 Optimisation Bayésienne
- 5 Comparaison des Méthodes

Le Contexte de l'Apprentissage

- Le Machine Learning consiste à **apprendre** à partir des données
- Cependant, tout n'est pas appris automatiquement
- On doit distinguer entre la **configuration interne** et la **configuration externe** d'un modèle



Définition

Variables de configuration **internes** au modèle.

Origine

Estimés (**appris**) à partir des données pendant l'entraînement.

Exemples

- **Poids** dans les Réseaux de Neurones Artificiels
- **Coefficients** en Régression Linéaire : $\theta = (\theta_0, \theta_1, \dots, \theta_n)$
- **Centroides** dans k-Means

Définition

Variables de configuration **externes** au modèle, définies **avant** l'entraînement.

Fonction

Contrôlent le **processus d'apprentissage** lui-même.

Exemples

Taux d'apprentissage (η), Régularisation (λ), Nombre d'époques

Paramètres vs Hyperparamètres

Caractéristique	Paramètres	Hyperparamètres
Appris des données ?	Oui	Non
Défini par l'humain ?	Non	Oui
Moment de définition	Pendant l'entraînement	Avant l'entraînement
Rôle	Définir l'état du modèle	Définir la structure/processus

Point Clé

Les hyperparamètres déterminent **comment** le modèle apprend, tandis que les paramètres sont **ce que** le modèle apprend.


Le Problème du Réglage (Tuning Problem)

Le Défi

Le modèle **ne peut pas apprendre** les hyperparamètres → on doit les trouver nous-mêmes !

L'Objectif

Trouver les hyperparamètres λ qui donnent le **meilleur score de validation**.



On cherche λ^* qui **maximise** ce score.

Grid Search : La Méthode Exhaustive

Principe


Définir un ensemble **fini** de valeurs pour chaque hyperparamètre et évaluer **toutes les combinaisons**.

Exemple

$\eta \in \{0.001, 0.01, 0.1\}$

$\lambda \in \{0.1, 1, 10\}$

$\Rightarrow 9$ combinaisons à tester



Étapes 1 & 2

Étape 1 : Définir l'Espace de Recherche

- Learning Rate η : $\{10^{-3}, 10^{-2}, 10^{-1}\}$
- L1 λ : $\{0.01, 0.1\}$

Étape 2 : Construire la Grille

L'algorithme construit **toutes les combinaisons possibles** :

Grille :

$$\{(10^{-3}, 0.01), (10^{-3}, 0.1), (10^{-2}, 0.01), (10^{-2}, 0.1), (10^{-1}, 0.01), (10^{-1}, 0.1)\}$$

⇒ **6 combinaisons** à évaluer


Étapes 3 & 4

Étape 3 : Évaluer

- Entraîner un modèle pour **chaque** combinaison spécifique de la grille
- Calculer une métrique de performance (Accuracy, Précision, Recall, F1, etc.)

Étape 4 : Sélectionner

Identifier la combinaison qui a produit le **meilleur score**.



Grid Search + Cross-Validation

Problème


Train/Test simple → risque de surapprentissage aux hyperparamètres

Solution : k-Fold CV

Pour **chaque** combinaison de la grille :

- 1 Diviser en k parties
- 2 Entraîner k fois
- 3 Score = moyenne

Bénéfice : Le score représente la **stabilité** et la **généralisabilité** du modèle.



5-Fold CV

Orange = validation, Bleu = entraînement

Avantages du Grid Search

Simplicité

Conceptuellement **facile à comprendre** et à implémenter.

Couverture

Couvre **méthodiquement** tout l'espace de recherche défini.

"Aucune pierre n'est laissée de côté" (dans la grille).

Parallélisme

"Embarrassingly Parallel"

Chaque point de la grille est **indépendant** ; peut être entraîné sur différents cœurs CPU ou clusters GPU simultanément.

Inconvénients du Grid Search

La Malédiction de la Dimensionnalité

L'espace de recherche croît **exponentiellement** avec le nombre d'hyperparamètres.

$$\text{Coût} = k \times \prod_{i=1}^p n_i$$

Inefficacité

Dépense des **ressources égales** sur les régions prometteuses et non prometteuses.

Erreur de Discrétisation

Ne peut pas trouver de valeurs **entre** les points de la grille.

Si l'optimal est $\lambda^* = 0.053$, mais la grille est $\{0.01, 0.05, 0.1\}$, Grid Search se contentera d'une valeur sous-optimale.

Random Search

La Méthode Stochastique


Limites du Grid Search

Explosion Combinatoire

Paramètres	Combinaisons
2 × 10 valeurs	100
3 × 10 valeurs	1 000
5 × 10 valeurs	100 000

Problème

Rigide : teste **toutes** les intersections, même les zones inutiles.



Rouge = essais gaspillés

Définition

Une technique de réglage des hyperparamètres qui sélectionne des combinaisons **au hasard** dans l'espace de recherche pour un nombre fixe d'itérations.

Grid Search

*"Vérifier ces 100 combinaisons **spécifiques**."*

Random Search

*"Vérifier **n'importe quelles** 100 combinaisons dans ces limites."*

Étape 1 (Distributions)


Définir des Distributions au lieu de Valeurs

Au lieu de définir des valeurs spécifiques (ex : $\{10, 20, 30\}$), on définit des **distributions statistiques**.

Paramètres Continus

Définis comme une **plage**

Ex : Taux d'apprentissage entre 10^{-5} et 10^{-1}



Continu

Paramètres Discrets

Définis comme une **liste d'options**

Ex : Optimiseur $\in \{'SGD', 'Adam', 'RMSprop'\}$



Discret

Étape 2 (Budget)

Random Search nécessite un Budget Computationnel

On doit définir n : Le **nombre d'itérations** (ou "essais").

Différence Clé avec Grid Search

- **Grid Search** : La taille de la grille dicte le coût
- **Random Search** : On dicte le coût

Flexibilité

n peut être 10, 50 ou 1000 selon les ressources de temps disponibles.

"J'ai 1 heure de temps GPU" $\Rightarrow$ Calculer combien d'essais sont possibles.

Étapes 3 & 4 (Exécution)

Étape 3 : Échantillonner


Tirer aléatoirement λ_i depuis les distributions.

Étape 4 : Évaluer

Entraîner avec λ_i + enregistrer le score.

Boucle

Répéter n fois → choisir le meilleur.



Uniforme

Toutes les valeurs équiprobables.

$$\lambda \sim \text{Uniform}(0.01, 0.1)$$

Log-Uniforme

Pour plusieurs ordres de grandeur.

$$\eta \sim \text{LogUniform}(10^{-5}, 10^{-1})$$

Règle Pratique

Log-Uniforme pour learning rate, régularisation (ordres de grandeur).

Uniforme pour le reste.

Random Search : Avantages & Limites

Avantages

- Flexible : pause/stop à tout moment
- Explore entre les points de grille
- Efficace en haute dimension

Limites

- Stochastique (variance)
- **Pas de mémoire** : n'apprend pas des essais précédents

Règle des 60

Avec **60 essais**, 95% de chance de trouver un modèle dans le top 5%.

Optimisation Bayésienne

La Recherche Informée

Idée Clé

Contrairement à Grid/Random Search, l'optimisation bayésienne choisit les hyperparamètres **en se basant sur les résultats des essais précédents**.

Comment ?

Les résultats passés forment un **modèle probabiliste** :

$$P(\text{score} \mid \text{hyperparamètres})$$

Ce modèle prédit quels hyperparamètres vont **probablement** donner un bon score.

Avantage

Gain de temps considérable en **éliminant les combinaisons non pertinentes**.

- ❶ L'Espace de Recherche – Où chercher ?
- ❷ La Fonction Objectif – Quoi optimiser ?
- ❸ Le Modèle de Substitution (Surrogate) – Comment prédire ?
- ❹ La Fonction de Sélection (Acquisition) – Comment choisir ?
- ❺ L'Historique – Qu'a-t-on déjà essayé ?

1. L'Espace de Recherche

Grid Search

Liste de valeurs fixes :

$$\eta \in \{0.001, 0.01, 0.1\}$$

$$C \in \{0.1, 1, 10\}$$

Opt. Bayésienne

Distributions de probabilités :

$$\eta \sim \text{LogUniform}(10^{-4}, 10^{-1})$$

$$C \sim \text{LogUniform}(10^{-2}, 10^2)$$

Pourquoi des distributions ?

Permet d'explorer l'espace de manière **continue** et **adaptative**.

2. La Fonction Objectif

Définition

La fonction objectif prend les hyperparamètres en entrée et retourne un **score** à optimiser.



Exemples de scores

- Accuracy sur validation (à **maximiser**)
- Loss sur validation (à **minimiser**)

3. Le Modèle de Substitution (Surrogate)

Définition

Représentation **probabiliste** de la fonction objectif, construite à partir des essais précédents.

Rôle

Prédire le score pour des hyperparamètres **sans entraîner** le modèle.

$$\lambda \xrightarrow{\text{Surrogate}} \text{score prédit}$$

Deux types principaux

- **Processus Gaussien (GP)** – modélise $P(y|\lambda)$
- **TPE** (Tree-structured Parzen Estimator) – modélise $P(\lambda|y)$

4. La Fonction de Sélection (Acquisition)

Définition

Critère pour choisir la **prochaine combinaison** d'hyperparamètres à tester.

Le choix le plus courant : Expected Improvement (EI)

"De combien s'attend-on à améliorer le meilleur score ?"

Équilibre entre :

- **Exploitation** : tester là où on prédit un bon score
- **Exploration** : tester là où on est incertain

5. L'Histoire

Définition

L'ensemble des combinaisons déjà testées avec leurs scores.

$$\text{Historique} = \{(\lambda_1, y_1), (\lambda_2, y_2), \dots, (\lambda_n, y_n)\}$$


Utilisation

- Le **Surrogate** s'entraîne sur l'historique
- La **Fonction de Sélection** l'utilise pour choisir le prochain point

C'est la "Mémoire"

C'est ce qui différencie l'optimisation bayésienne de Grid/Random Search !

Le Cycle Complet




Algorithme

- 1 Initialiser avec quelques points aléatoires
- 2 Répéter : Surrogate $\rightarrow$ Sélection $\rightarrow$ Évaluation $\rightarrow$ Historique

Comparaison


Les 3 Méthodes d'Optimisation

Grid Search



Exhaustif sur une grille

Random Search



Échantillonnage aléatoire

Opt. Bayésienne



Recherche informée

Non Informé $\longrightarrow$ Informé

Tableau Comparatif

Critère	Grid	Random	Bayésienne
Simplicité	+++	++	+
Efficacité	+	++	+++
Parallélisable	+++	+++	+
Peu d'essais	+	++	+++

Outils

Grid/Random : scikit-learn | **Bayésienne** : Optuna, Hyperopt

Quand Utiliser Quelle Méthode ?

Grid Search

- 1-3 hyperparamètres
- Valeurs standard connues
- Reproductibilité requise

Random Search

- > 4 hyperparamètres
- Budget temps fixe
- Baseline rapide

Bayésien (GP)

- Entraînement coûteux
- Paramètres continus
- < 100 observations

TPE

- Variables catégorielles
- Espaces conditionnels
- Beaucoup d'observations

Principe Fondamental

Il n'existe **aucun optimiseur unique** qui soit le meilleur pour tous les problèmes.

Caractéristique	Grid	Random	Bayésienne
Stratégie	Exhaustive	Stochastique	Informée
Efficacité	Faible	Moyenne	Élevée
Risque	Explosion dim.	Variance	Cold start
Parallélisable	+++	+++	+

Grid Search

- **Exhaustif**
- Déterministe
- Coût $O(\prod n_i)$

Random Search

- **Stochastique**
- Coût contrôlé
- Top 5% en 60 essais

Bayésien

- **Informé**
- Surrogate + Acquisition
- Exploration/Exploitation

A Retenir

- **Toujours** utiliser avec la **Validation Croisée**
- Utiliser des échelles **logarithmiques** pour η , λ

Guide de Décision

$\text{Dim} \leq 3 \Rightarrow$ **Grid** | $\text{Dim} > 4 \Rightarrow$ **Random** | Coût élevé $\Rightarrow$ **Bayésien**

Des questions ?